

Tópicos Especiais: Processamento de
Linguagem Natural

A Engenharia de Textos (PNL Básica)

Disciplina: Extração e Preparação de Dados
(IBM8915)

Data: 09/04 (Quinta-feira)



O Problema do Texto Bruto

- ▶ **A Realidade:** O maior volume de dados do mundo está em comentários, reviews e e-mails.
- ▶ **O Desafio Matemático:** Algoritmos de **Machine Learning** (como regressão ou redes neurais) só fazem cálculos. Eles não leem o alfabeto.
- ▶ **A Missão de Hoje:** Como transformamos o sentimento de "Odiei o produto" em números preditivos para um modelo classificador?




A Faxina de Texto no Pandas

- ▶ **O Acessor `.str`:** Assim como usamos o `.dt` para acessar dados de tipo `datetime`, usamos o `.str` para vetorizar operações de texto de forma eficiente.

- ▶ **Padronização de Caixa:** (`df['texto'].str.lower()` "gato" como palavras totalmente diferentes).

- ▶ **Remoção de Ruído:** Uso de Expressões Regulares (RegEx) encadeadas com `.str.replace()` para apagar pontuações e símbolos inúteis.



| Tokens e Stopwords



Tokenização

A quebra do texto bruto em unidades menores (palavras ou tokens). É o processo de fragmentar a frase em partes analisáveis.



Stopwords

Conectivos e artigos irrelevantes (como "o", "a", "de") que não carregam sentimento ou significado preditivo. Devem ser descartados.



Lematização

Redução das palavras aos seus radicais ou infinitivos (ex: "correndo" se transforma em "correr"). Reduz a dimensionalidade da base.

Check de Aprendizado: A Matriz Matemática

O Cenário

Você tem duas frases limpas em sua base de dados:

- 1) *"produto excelente"*
- 2) *"produto quebrado"*

A Pergunta:

Como o método **CountVectorizer** do Scikit-Learn vai transformar essas duas frases em um DataFrame numérico estruturado?

A Resposta (Bag-of-Words)

O algoritmo cria colunas para cada palavra única: 'produto', 'excelente', 'quebrado'.

- ▶ **Linha 1:** 'produto'=1, 'excelente'=1, 'quebrado'=0
- ▶ **Linha 2:** 'produto'=1, 'excelente'=0, 'quebrado'=1

Transformamos texto puro em uma matriz matemática perfeitamente pronta para Machine Learning.

Hands-on: O Analista de Sentimentos (Lab 16)




Missão no Jupyter:

- ▶ **Carga e Padronização:** Carregar o dataset de E-commerce e encadear o e o para limpar o ruído do texto bruto.
`.str.replace()` `.str.lower()`
- ▶ **O Filtro:** Aplicar a remoção de **stopwords** nas frases das reviews dos clientes.
- ▶ **Feature Extraction:** Usar o **CountVectorizer** (Bag of Words) do Scikit-Learn para converter a coluna de texto limpo em uma matriz numérica de frequência.

O Paradigma da Ordem (Séries Temporais)

- ▶ **A Lei do Tempo:** O que difere dados normais de dados temporais? Na quarta dimensão, a **ordem** importa estritamente.
- ▶ **O Erro do Embaralhamento:** Se você embaralhar as linhas de um histórico de previsão de vendas, o modelo perde a capacidade de entender sazonalidade.
- ▶ **A Autocorrelação:** Em séries temporais, o evento de "hoje" é fortemente influenciado pelo evento de "ontem".



Agregação Dinâmica (Resample)

```
# Convertendo dados diários para faturamento mensal  
df_mensal = df.resample('M').sum()
```


 Conceito visual de downsampling agrupando gráficos de barras

- ▶ **O que é Resampling?** É uma operação de grupo baseada estritamente em intervalos de tempo.
- ▶ **Downsampling:** A agregação de dados de alta frequência (ex: diária) para frequências menores (ex: mensal) utilizando funções de agregação matemática.
- ▶ **A Vantagem:** Reduz o ruído diário e revela a tendência macro do negócio para a diretoria.

A Máquina do Tempo (Shift e Lags)

```
# Criando a variável do passado (Lag)
df['Vendas_Ontem'] = df['Vendas_Hoje'].shift(1)
```

- ▶ **O Deslocamento (Shifting):** Refere-se à movimentação dos dados para trás e para a frente no tempo, deixando o índice inalterado.
- ▶ **Criando Lags:** O uso do comando `.shift(1)` alinha o "valor do dia anterior" na mesma linha do "valor de hoje", criando previsibilidade.
- ▶ **O Preço:** Quando fazemos deslocamentos, dados ausentes (**NaN**) são obrigatoriamente introduzidos no início da série.



Check de Aprendizado: O Risco do Tempo

⚠️ O Cenário Crítico

Você usou o código abaixo para treinar um modelo para prever a coluna

"Vendas_Amanha":

```
df['Vendas_Amanha'] =  
df['Vendas_Hoje'].shift(-1)
```

A acurácia do seu modelo foi de incríveis **99,9%**.

Pergunta: Por que esse modelo seria completamente inútil e causaria a sua demissão se colocado em produção hoje?

💀 A Resposta (Data Leakage)

Você criou uma máquina do tempo quebrada. Ao usar o **shift(-1)**, você puxou a venda do futuro (que você quer prever) para a linha de treinamento de hoje. O modelo tirou nota máxima porque ele **já tinha o gabarito** durante o treino (Vazamento de Dados). Em produção no mundo real, a venda de amanhã ainda não existe, a coluna virá vazia e o modelo falhará miseravelmente.

Hands-on: O Mestre do Tempo (Lab 17)



Missão Final de Dados:

- ▶ **Carga e Indexação:** Converter coluna para datetime e setar a data como índice absoluto do DataFrame.
- ▶ **Agregação Mensal:** Usar o `.resample()` para transformar o registro diário em um DataFrame de faturamento mensal.
- ▶ **Engenharia de Lags:** Usar `.shift(1)` e `.shift(2)` nas variáveis para criar "mes_anterior" e "dois_meses_atras".
- ▶ **Tratamento:** Lidar tecnicamente com os NaN gerados pelo deslocamento inicial.

O Grande Salto

Bem-vindos à Orquestração

- **Missão Cumprida:** Esta é oficialmente a última aula de manipulação técnica dos dados em nível de script isolado.
- **O Portfólio Semanal:** Commit dos cadernos e `lab_16_nlp` `lab_17_ts` finalizados no repositório.
- **A Revolução (Aula 16):** Na próxima aula, a disciplina passará por uma virada arquitetural gigantesca: instalaremos e rodaremos pipelines automatizados com o [Apache Airflow](#).



Image Sources



<https://cdn.dribbble.com/userupload/45982106/file/7dd4e50cac4084277ac9ab22c2ecd318.jpeg?resize=400x0>

Source: dribbble.com



[https://images.cults3d.com/8rMZAk7LyddNaTcxEw2PRkp6stc=/516x516/filters:no_upscale\(\)/https://fbi.cults3d.com/uploaders/37930756/illustration-file/4ff09ea4-4c4b-4e5e-9f53-7357066e98fe/Dizain-biez-nazvaniia.png](https://images.cults3d.com/8rMZAk7LyddNaTcxEw2PRkp6stc=/516x516/filters:no_upscale()/https://fbi.cults3d.com/uploaders/37930756/illustration-file/4ff09ea4-4c4b-4e5e-9f53-7357066e98fe/Dizain-biez-nazvaniia.png)

Source: cults3d.com




<https://forum-cdn.knime.com/uploads/default/30b1c87eae5e501f371d1694fc29a94194aa5ffa>

Source: forum.knime.com



https://img.freepik.com/premium-vector/jupyter-notebook-3d-icon-project-jupyter_1115399-392.jpg

Source: www.freepik.com



https://aaqr.org/images/article_images/2024/feature/23-12-0317.jpg

Source: aaqr.org



<https://fastercapital.com/i/Time-series-aggregation--Analyzing-Data-Trends-Over-Time--Visualizing-Time-series-Data.webp>

Source: fastercapital.com

Image Sources



https://miro.medium.com/1*N71umOcckrgKqOXFnJhdPg.png

Source: [medium.com](https://miro.medium.com/1*N71umOcckrgKqOXFnJhdPg.png)



<https://uxwing.com/wp-content/themes/uxwing/download/brands-and-social-media/apache-airflow-icon.png>
Source: [uxwing.com](https://uxwing.com/wp-content/themes/uxwing/download/brands-and-social-media/apache-airflow-icon.png)